

Algorithmen und Datenstrukturen: Übung 4

Tanja Zast, Alexander Waldenmaier

2. Dezember 2020

Aufgabe 4.1

- a) Wenn mit Wahrscheinlichkeit $p' = \frac{2}{3}$ zwei Marsianer am selben Tag Geburtstag haben, dann beträgt die Wahrscheinlichkeit für völlig unterschiedliche Geburtstage $p = \frac{1}{3}$. Mit $m = 687$ ergibt die Formel aus dem Skript dann für die gesuchte Anzahl n an Marsianern:

$$\begin{aligned}\prod_{i=1}^{n-1} \frac{m-1}{m} &= p \approx e^{-\frac{(n-\frac{1}{2})^2}{2m}} \\ \ln p &\approx -\frac{(n-\frac{1}{2})^2}{2m} \\ 2m \ln p &\approx -\left(n-\frac{1}{2}\right)^2 \\ \sqrt{-2m \ln p} &\approx n - \frac{1}{2} \\ n &\approx \sqrt{-2m \ln p} + \frac{1}{2} \\ n &\approx \sqrt{-2 \cdot 687 \ln \frac{1}{3}} + \frac{1}{2} \approx 39,3522 \\ \Rightarrow n &= 40\end{aligned}$$

Ab 40 Marsianern beträgt die Wahrscheinlichkeit für mindestens eine Dopplung der Geburtstage mehr als $\frac{2}{3}$.

- b) Die Wahrscheinlichkeit, dass bei n Einträgen in einer m großen Hashtabelle eine Kollision auftritt, beträgt:

$$p = 1 - \prod_{i=1}^{n-1} \frac{m-1}{m} \approx 1 - e^{-\frac{(n-\frac{1}{2})^2}{2m}}$$

Mit der Bedingung $p > \frac{2}{3}$ und unter Verwendung der Approximation folgt:

$$\begin{aligned}\frac{2}{3} &\lesssim 1 - e^{-\frac{(n-\frac{1}{2})^2}{2m}} \\ \frac{1}{3} &\gtrsim e^{-\frac{(n-\frac{1}{2})^2}{2m}} \\ \ln \frac{1}{3} &\gtrsim -\frac{(n-\frac{1}{2})^2}{2m} \\ 2m \ln \frac{1}{3} &\gtrsim -\left(n-\frac{1}{2}\right)^2 \\ \sqrt{-2m \ln \frac{1}{3}} &\lesssim n - \frac{1}{2} \\ n &\gtrsim \sqrt{-2m \ln \frac{1}{3}} + \frac{1}{2}\end{aligned}$$

Aufgabe 4.2

Gegeben: $S = \{92, 19, 83, 37, 16, 57, 61\}, m = 11$

a)

0	/	→
1	/	→
2		→ 57 /
3	/	→
4		→ 92 → 37 /
5		→ 16 /
6		→ 83 → 61 /
7	/	→
8		→ 19 /
9	/	→
10	/	→

Es entstehen zwei Kollisionen: 92 kollidiert mit 57 am Index 4, 83 kollidiert mit 61 am Index 6.

b)

0	/	→
1	/	→
2		→ 57 /
3	/	→
4		→ 92 /
5		→ 37 /
6		→ 83 /
7		→ 16 /
8		→ 19 /
9		→ 61 /
10	/	→

s	92	19	83	37	16	57	61
i	0	0	0	1	2	0	3

Es entstehen insgesamt 6 Kollisionen.

c)

0	/	→
1		→ 37 /
2		→ 57 /
3	/	→
4		→ 92 /
5		→ 16 /
6		→ 83 /
7		→ 61 /
8		→ 19 /
9	/	→
10	/	→

$$\begin{aligned}
 h(37, 1) &= (h_1(37) + 1 \cdot h_2(37)) \mod 11 \\
 &= (4 + (1 + ((37 - 1) \mod (11 - 1)))) \mod 11 \\
 &= (4 + (1 + 36 \mod 10)) \mod 11 \\
 &= (4 + 4) \mod 11 \\
 &= 8
 \end{aligned}$$

$$\begin{aligned}
 h(37, 2) &= (h_1(37) + 2 \cdot h_2(37)) \mod 11 \\
 &= (4 + 2 \cdot 4) \mod 11 \\
 &= 1
 \end{aligned}$$

$$\begin{aligned}
 h(61, 1) &= (h_1(61) + 1 \cdot h_2(61)) \mod 11 \\
 &= (6 + (1 + ((61 - 1) \mod (11 - 1)))) \mod 11 \\
 &= (4 + (1 + 60 \mod 10)) \mod 11 \\
 &= (4 + 1) \mod 11 \\
 &= 5
 \end{aligned}$$

$$\begin{aligned}
 h(61, 2) &= (h_1(61) + 2 \cdot h_2(61)) \mod 11 \\
 &= (4 + 2 \cdot 1) \mod 11 \\
 &= 6
 \end{aligned}$$

$$\begin{aligned}
 h(61, 3) &= (h_1(61) + 3 \cdot h_2(61)) \mod 11 \\
 &= (4 + 3 \cdot 1) \mod 11 \\
 &= 7
 \end{aligned}$$

s	92	19	83	37	16	57	61
i	0	0	0	2	0	0	3

Es entstehen insgesamt 5 Kollisionen.

Aufgabe 4.3

Aussage:

$$A : \forall h(s_i) \exists s_1, s_2 \in S \subset U \mid n = |S|, |U| > m(n - 1) : h(s_1) = h(s_2)$$

Gegenaussage:

$$\bar{A} : \forall h(s_i) \forall s_1, s_2 \in S \subset U \mid n = |S|, |U| > m(n - 1) : h(s_1) \neq h(s_2)$$

Die Gegenaussage gilt es nun zu widerlegen.

Damit alle Schlüssel des Universums einen eigenen Platz in der Hashtabelle bekommen können (sonst würden zwangsläufig Kollisionen auftreten), muss gelten:

$$\begin{aligned}
 m &\geq |U| \\
 \stackrel{\bar{A}}{\Rightarrow} m &\geq |U| \stackrel{!}{>} m(n - 1) \\
 m &\not\geq m(n - 1), \text{ mit } n \geq 2
 \end{aligned}$$

Die Gegenaussage wurde widerlegt, womit A gilt.

Aufgabe 4.4

Wir nehmen an, dass zwei unterschiedliche Werte x_1, x_2 durch die k Hash-Funktionen auf die selben Indizes abgebildet werden. Ist x_1 bereits gespeichert, dann werden beim Abspeichern von x_2 keine Bits verändert. Wird nun beispielsweise x_1 gelöscht, so würde eine Abfrage (bloomCheck) von x_2 *false* ergeben, da alle zugehörigen Bits bei der Löschung von x_1 auf *false* gesetzt wurden. Das widerspricht dem Anspruch des BloomFilters, keine False Negatives herauszugeben.

Aufgabe 4.5

Qualitativ lässt sich sagen: Je mehr Hash-Funktionen, desto geringer sollte die Wahrscheinlichkeit für false positives werden, da die Anzahl an Bits, die identisch sein müssen, zunimmt. Andererseits werden mit mehr Hash-Funktionen auch mehr Bits befüllt, der Belegungsgrad wird höher, wodurch irgendwann wieder mehr false positives auftreten. Dies zeigt sich an der Formel aus dem Skript:

$$\begin{aligned} P(\text{false positive}) &= (1 - p)^k \\ &\approx \left(1 - \underbrace{e^{-\frac{nk}{m}}}_{p=P(A[i]=\text{FALSE})}\right)^k \end{aligned}$$

Die minimale Kollisionswahrscheinlichkeit liegt bei $k = 7$ vor. Im Folgenden sind die Werte für alle zulässigen k und $n = 100, m = 1000$ aufgetragen und grafisch dargestellt:

k	2	3	4	5	6	7	8	9	10	11	12
P [%]	3.2859	1.7411	1.1813	0.9431	0.8436	0.8194	0.8455	0.9127	1.0186	1.1650	1.3561




Abbildung 1: Wahrscheinlichkeit p für false positives bei k Hash-Funktionen ($n = 100, m = 1000$)

Aufgabe 4.6

Abgabe in DOMjudge. Teamname: "test"